



ITMO UNIVERSITY

Saint Petersburg, Russia

# Системы оцувствления роботов

[bia@itmo.ru](mailto:bia@itmo.ru)

# Данные с датчиков

- ✓ Получение данных с датчиков не представляет сложности, однако качество этих данных оставляет желать лучшего, так как датчики не совершенны и присутствуют шумы в сигналах.

# Ограничения в данных

При разработке системы должны быть учтены:

Особенности обработки данных

Например, требуется время на обработку

Характер возможного  
изменения потока данных

Например, робот имеет ограничение на  
максимальное ускорение

Зачастую необходимо ввести  
дополнительный модуль, который «следит»  
и ограничивает систему для обеспечения  
возможности восприятия.

Мы будем рассматривать методы уменьшения  
влияния выбросов чуть позже в ходе курса.

# Синхронизация и использование общего времени

- ✓ Компьютер не имеет собственного аппаратного таймера, поэтому не подходит для работы с системами реального времени. Однако эту проблему можно решить в некотором приближении.
- ✓ Подсистемы и модули системы должны использовать общее время для корректной работы, поэтому они должны использовать реальное время.

Либо нечувствительные к смещению времени данные.

# Оценка состояния

- ✓ Для подвижных роботов, оценка состояния как правило заключается в определении положения и ориентации.

**Важно!** Наряду с оценкой состояния рассматривается оценка параметров системы.

Состояние характеризуется физической величиной, которая меняется со временем, параметр же постоянен во времени (в интервале).



# Примеры

## ✓ Чай

Ключевая характеристика → температура.

## ✓ Резистор

Ключевая характеристика → сопротивление.

Проводим измерение с помощью термометра, получаем измерение в 50 градусов, и еще раз измеряем, получаем 49,8 градусов... еще раз и еще раз. Так какова температура чая?

Случай с резистором разберем подробно.

# Метод наименьших квадратов

Наиболее вероятное значение неизвестного параметра - это то, что минимизирует сумму квадратов ошибок между тем, что мы наблюдаем, и тем, что мы ожидаем.

Пример: 1 kOhm резистор

Погрешность до 5% (золотая полоса)

Мультиметр имеет погрешность

Человек, выполняющий измерения, не особо то аккуратен.

**Каково же истинное значение сопротивления резистора?**



№ измерения	Сопротивление, Ohm
1	1068
2	9888
3	1002
4	996

# Оценка сопротивления

- ✓ Пусть  $x$  – сопротивление. Предположим, что  $x$  имеет постоянное значение, которое не известно.
- ✓ Мы делаем измерение и получаем значение сопротивления  $y$ .

Тогда, мы можем ввести некоторую модель измерения

$$y = x + v$$

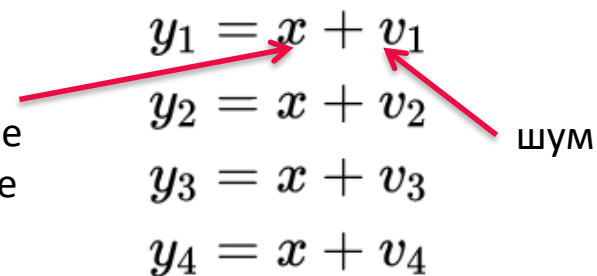


# Оценка сопротивления

Истинное значение

$$\begin{aligned}y_1 &= x + v_1 \\y_2 &= x + v_2 \\y_3 &= x + v_3 \\y_4 &= x + v_4\end{aligned}$$

шум



Квадратичная ошибка:

$$\begin{aligned}e_1^2 &= (y_1 - x)^2 \\e_2^2 &= (y_2 - x)^2 \\e_3^2 &= (y_3 - x)^2 \\e_4^2 &= (y_4 - x)^2\end{aligned}$$

$$\hat{x}_{LS} = \operatorname{argmin}_x (e_1^2 + e_2^2 + e_3^2 + e_4^2) = \mathcal{L}_{LS}(x)$$

**Функция потерь** - мера расхождения между истинным значением оцениваемого параметра и оценкой параметра.

# Метод наименьших квадратов

- ✓ Наиболее вероятным значением неизвестного параметра является то, что минимизирует сумму квадратов ошибок между тем, что мы наблюдаем, и тем, что мы ожидаем.

$$\hat{x}_{LS} = \operatorname{argmin}_x (e_1^2 + e_2^2 + e_3^2 + e_4^2) = \mathcal{L}_{LS}(x)$$

- ✓ В матричной форме

$$\mathbf{e} = \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix} = \mathbf{y} - \mathbf{H}\mathbf{x} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} x$$



$\mathbf{H}$  - имеет размеры  $m$  на  $n$ , где  $m$  - количество измерений, а  $n$  - количество неизвестных или параметров, которые мы хотим оценить.

# Метод наименьших квадратов

✓ Теперь мы можем выразить МНК в след. форме:

$$\begin{aligned}\mathcal{L}_{\text{LS}}(x) &= e_1^2 + e_2^2 + e_3^2 + e_4^2 = \mathbf{e}^T \mathbf{e} \\ &= (\mathbf{y} - \mathbf{H}x)^T (\mathbf{y} - \mathbf{H}x) \\ &= \mathbf{y}^T \mathbf{y} - x^T \mathbf{H}^T \mathbf{y} - \mathbf{y}^T \mathbf{H}x + x^T \mathbf{H}^T \mathbf{H}x\end{aligned}$$

Нужно минимизировать квадратичную ошибку по отношению к нашему истинному сопротивлению  $x$ .

Мы можем сделать это, взяв производную функции ошибки по  $x$  и приравняв к 0.

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial x} \Big|_{x=\hat{x}} &= -\mathbf{y}^T \mathbf{H} - \mathbf{y}^T \mathbf{H} + 2\hat{x}^T \mathbf{H}^T \mathbf{H} = 0 \\ -2\mathbf{y}^T \mathbf{H} + 2\hat{x}^T \mathbf{H}^T \mathbf{H} &= 0\end{aligned}$$

$\hat{x}_{\text{LS}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$  - Минимизирует среднюю квадратичную ошибку

# Важно!

- ✓ Если матрица  $(\mathbf{H}^T \mathbf{H})^{-1}$  существует, т.е.  $\mathbf{H}^T \mathbf{H}$  не является сингулярной матрицей.
- ✓ Физический смысл заключается в том, что у нас должно быть как минимум  $m \geq n$ , где  $m$  – количество измерений,  $n$  – количество неизвестных параметров... Это условие обычно выполняется...

## Возвращаясь к задаче...

$$\mathbf{y} = \begin{bmatrix} 1068 \\ 988 \\ 1002 \\ 996 \end{bmatrix} \quad \mathbf{H} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \quad = \left( \begin{bmatrix} 1111 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 1111 \end{bmatrix} \begin{bmatrix} 1068 \\ 988 \\ 1002 \\ 996 \end{bmatrix} = \frac{1}{4} (1068 + 988 + 1002 + 996) = 1013.5 \text{ Ohms}$$

Возможно, это было  
очевидное решение...

Теперь, у нас есть другое обоснование для  
использования среднего арифметического:  
минимизирует критерий наименьших квадратов.

Важно! Мы рассматривали линейную модель измерения и при этом измерения имели одинаковые веса (одинаковый шум). На практике, это не всегда так!

# А если у нас разные шумы при измерениях?

Далее, мы будем оценивать несколько параметров. Например, нужно оценить несколько значений сопротивления одновременно.

Набор из  $m$  измерений, которые связаны с набором из  $n$  неизвестных параметров через линейную модель.

Новая модель измерений:

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = \mathbf{H} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} v_1 \\ \vdots \\ v_m \end{bmatrix}$$
$$\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{v}$$

В обычной МНК мы подразумевали, что дисперсия одинаковая для каждого шума.

$$\mathbb{E}[v_i^2] = \sigma_i^2, \quad (i = 1, \dots, m)$$

$$\mathbf{R} = \mathbb{E}[\mathbf{v}\mathbf{v}^T] = \begin{bmatrix} \sigma_1^2 & 0 \\ & \ddots \\ 0 & \sigma_m^2 \end{bmatrix}$$

# Метод взвешенных наименьших квадратов

- ✓ Если предположим, что шумы не зависят друг от друга, имеют **разную дисперсию**, мы можем определить нашу ковариацию шума:

$$\mathbb{E}[v_i^2] = \sigma_i^2, \quad (i = 1, \dots, m) \quad \mathbf{R} = \mathbb{E}[\mathbf{v}\mathbf{v}^T] = \begin{bmatrix} \sigma_1^2 & 0 \\ & \ddots \\ 0 & \sigma_m^2 \end{bmatrix}$$

Тогда можно записать метод **взвешенных наименьших квадратов**:

$$\begin{aligned} \mathcal{L}_{\text{WLS}}(\mathbf{x}) &= \mathbf{e}^T \mathbf{R}^{-1} \mathbf{e} \\ &= \frac{e_1^2}{\sigma_1^2} + \frac{e_2^2}{\sigma_2^2} + \dots + \frac{e_m^2}{\sigma_m^2} \end{aligned}$$

$$\text{Где } \begin{bmatrix} e_1 \\ \vdots \\ e_m \end{bmatrix} = \mathbf{e} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} - \mathbf{H} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

# Еще раз посмотрим на обычный МНК

✓ Если зададим одинаковую дисперсию:

$$\begin{aligned}\mathcal{L}_{\text{WLS}}(\mathbf{x}) &= \frac{e_1^2}{\sigma^2} + \frac{e_2^2}{\sigma^2} + \dots + \frac{e_m^2}{\sigma^2} \\ &= \frac{1}{\sigma^2}(e_1^2 + \dots + e_m^2)\end{aligned}$$

Так как дисперсия одинаковая для всех измерений, наша последняя модификация никак не повлияла на результат.



# Применяем новый критерий

$$\begin{aligned}\mathcal{L}_{\text{WLS}}(\mathbf{x}) &= \mathbf{e}^T \mathbf{R}^{-1} \mathbf{e} \\ &= (\mathbf{y} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x})\end{aligned}$$

Для минимизации, как и в предыдущем случае, берем производную по параметру.

$$\left. \frac{\partial \mathcal{L}}{\partial \mathbf{x}} \right|_{\mathbf{x}=\hat{\mathbf{x}}} = \mathbf{0} = -\mathbf{y}^T \mathbf{R}^{-1} \mathbf{H} + \hat{\mathbf{x}}^T \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}$$

В общем случае, когда у нас есть  $n$  неизвестных параметров в нашем векторе  $\mathbf{x}$ , этим производным будет градиент.

$$\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \hat{\mathbf{x}}_{\text{WLS}} = \mathbf{H}^T \mathbf{R}^{-1} \mathbf{y} \quad \longrightarrow \quad \hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{y}$$

## Пример 2

Стандартное отклонение необходимо возвести в квадрат!

$$\mathbf{H} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} 1068 \\ 988 \\ 1002 \\ 996 \end{bmatrix} \quad \mathbf{R} = \begin{bmatrix} \sigma_1^2 & & & \\ & \sigma_2^2 & & \\ & & \sigma_3^2 & \\ & & & \sigma_4^2 \end{bmatrix} = \begin{bmatrix} 400 & & & \\ & 400 & & \\ & & 4 & \\ & & & 4 \end{bmatrix}$$

Можно заметить, что полученное значение намного ближе к измеренному более точным прибором значению.

№	Инструмент 1, погрешность 20 Ohm	Инструмент 1, погрешность 2 Ohm
1	1068	
2	988	
3		1002
4		996

$$\begin{aligned} \hat{x}_{\text{WLS}} &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{y} \\ &= \left( [1111] \begin{bmatrix} 400 & & & \\ & 400 & & \\ & & 4 & \\ & & & 4 \end{bmatrix}^{-1} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \right)^{-1} [1111] \begin{bmatrix} 400 & & & \\ & 400 & & \\ & & 4 & \\ & & & 4 \end{bmatrix}^{-1} \begin{bmatrix} 1068 \\ 988 \\ 1002 \\ 996 \end{bmatrix} \\ &= \frac{1}{1/400 + 1/400 + 1/4 + 1/4} \left( \frac{1068}{400} + \frac{988}{400} + \frac{1002}{4} + \frac{996}{4} \right) \\ &= 999.3 \text{ Ohms} \end{aligned}$$

# Сравнение: обычный и взвешенный МНК

Функция потерь

$$\mathcal{L}_{\text{LS}}(\mathbf{x}) = \mathbf{e}^T \mathbf{e}$$

$$\mathcal{L}_{\text{WLS}}(\mathbf{x}) = \mathbf{e}^T \mathbf{R}^{-1} \mathbf{e}$$

Оценка

$$\hat{\mathbf{x}}_{\text{LS}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$$

$$\hat{\mathbf{x}}_{\text{WLS}} = (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{y}$$

Ограничения

$$m \geq n$$

$$m \geq n$$

$$\sigma_i^2 > 0$$


Например, дополнительно почитать можно тут:

<https://textbooks.math.gatech.edu/ila/least-squares.html>

# Бесконечный поток данных ...

- ✓ Одним из предположений было: все данные под рукой (готовые). Это иногда вполне разумное предположение.
- ✓ Что делать, если вместо этого у нас есть **поток данных**?

**Пересчитывать решение МНК каждый раз, когда мы получаем новое измерение?  
Например, у нас датчик измеряет 10 раз в секунду.**



**В идеале** мы хотели бы использовать как можно больше измерений, чтобы получить точную оценку сопротивления.

Однако, если используем МНК, количество вычислительных ресурсов, которые нам понадобятся для решения наших уравнений, будет расти с увеличением размера вектора измерения.

# МНК на лету

- ✓ **Альтернатива:** попытаться использовать рекурсивный метод, поддерживающий текущую оценку параметра оптимальной для всех измерений, собранных до предыдущего временного шага, затем обновляет эту оценку, учитывая измерение на текущем временном шаге.
- ✓ Для этого мы используем **рекурсивный алгоритм**, постепенно обновляя нашу оценку по мере продвижения. Предположим, что у нас есть наилучшая оптимальная оценка в момент времени  $k-1$ . В момент времени  $k$  мы получаем новое измерение, которое предполагает, что имеем линейную модель измерения с гауссовским шумом.



# Линейная рекурсивная оценка МНК

- ✓ У нас есть оптимальная оценка для  $\hat{x}_{k-1}$  неизвестного параметра в момент времени  $k-1$
- ✓ Тогда, мы получаем новое значение в момент времени  $k$ :  $y_k = H_k x + v_k$

Задача: **рассчитать  $\hat{x}_k$  как функцию  $y_k$  и  $\hat{x}_{k-1}$**

# Линейная рекурсивная оценка

Можно воспользоваться рекурсивной линейной оценкой

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_{k-1} + \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k-1})$$

$\mathbf{K}_k$  называется матрицей поправочных коэффициентов, а внутрискобочная составляющая компонентой поправки, показывающей, насколько новое измерение соответствует предыдущей оценке.

**Обновляем новое состояние как линейная комбинация предыдущей наилучшей оценки и текущего измерения ошибки, умноженному на некоторый коэффициент.**

## Как найти $K_k$ ?

- ✓ Мы можем его рассчитать минимизируя критерий, схожий с оценкой наименьших квадратов, но с использованием вероятностной формулировки.
- ✓ Если мы хотим минимизировать сумму квадратов ошибок ожидаемых значений в момент времени  $k$ :
$$\mathcal{L}_{\text{RLS}} = \mathbb{E}[(x_k - \hat{x}_k)^2]$$
$$= \sigma_k^2$$

- ✓ Если у нас  $n$  неизвестных параметров

$$\mathcal{L}_{\text{RLS}} = \mathbb{E}[(x_{1k} - \hat{x}_{1k})^2 + \dots + (x_{nk} - \hat{x}_{nk})^2]$$
$$= \text{Trace}(\mathbf{P}_k)$$



- ✓ Используя нашу линейную рекурсивную формулировку, выразим ковариацию как функцию  $K_k$

$$\mathbf{P}_k = (\mathbf{1} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k-1} (\mathbf{1} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Поскольку, чем меньше ковариация, тем лучше, именно при таком значении  $K$ , ковариация меньше, это можно показать через ряд матричных преобразований.

$$\mathbf{K}_k = \mathbf{P}_{k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

Используя полученные выражения, мы можем записать

$$\begin{aligned} \mathbf{P}_k &= \mathbf{P}_{k-1} - \mathbf{K}_k \mathbf{H}_k \mathbf{P}_{k-1} \\ &= (\mathbf{1} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k-1} \end{aligned}$$

# Рекурсивный алгоритм МНК

- ✓ Исходная оценка

$$\hat{\mathbf{x}}_0 = \mathbb{E}[\mathbf{x}]$$
$$\mathbf{P}_0 = \mathbb{E}\left[(\mathbf{x} - \hat{\mathbf{x}}_0)(\mathbf{x} - \hat{\mathbf{x}}_0)^T\right]$$

- ✓ Затем мы настраиваем нашу модель измерения, выбирая значения для нашей ковариации измерения и якобиан.

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x} + \mathbf{v}_k$$

- ✓ И пересчитываем значения

$$\mathbf{K}_k = \mathbf{P}_{k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$
$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_{k-1} + \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k-1})$$
$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k-1}$$

# Почему квадрат ошибки?

А не куб например? Есть несколько причин:

- ✓ Квадрат ошибки позволяет находить оптимальные параметры с относительно легким расчетом.
- ✓ Вторая причина связана с вероятностью и связью между наименьшим квадратом и оценкой максимального правдоподобия в допущении, что шум подчиняется нормальному закону распределения.

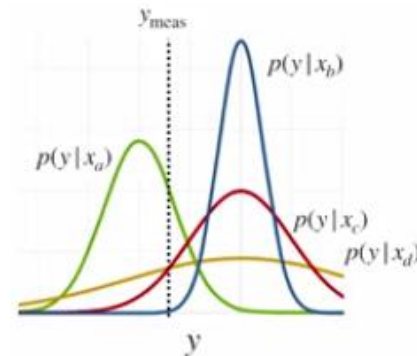
# Метод максимального правдоподобия

Имеем четыре возможных значения неизвестного параметра  $x$ ,  $x_a$  —  $x_d$  и каждое из них приводит к следующей условной вероятности в нашем измерении  $Y$ .

Какое значение  $x$  максимизирует условную вероятность, учитывая измерение  $y_{meas}$ ?

$$\hat{x} = \operatorname{argmax}_x p(y | x)$$

- ✓ Наибольшая плотность вероятности в измеренном месте определяется зеленой кривой!  $x_a$  является наиболее вероятным значением параметра  $x$  при данных измерениях.



# Модель измерения


Модель измерения

$$y = x + v$$

Мы можем преобразовать эту модель в условную вероятность при измерении, вводя некоторую плотность вероятности для шума:  $v \sim \mathcal{N}(0, \sigma^2)$

Тогда

$$p(y | x) = \mathcal{N}(x, \sigma^2).$$



# МНК и максимизация правдоподобия

- ✓ Плотность вероятности функции с нормальным распределением:

$$\mathcal{N}(z; \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(z-\mu)^2}{2\sigma^2}}$$

- ✓ Мы можем выразить нашу вероятность измерения для одного измерения:

$$\begin{aligned} p(y | x) &= \mathcal{N}(y; x, \sigma^2) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-x)^2}{2\sigma^2}} \end{aligned}$$

- ✓ Для нескольких независимых измерений

$$\begin{aligned} p(\mathbf{y} | x) &\propto \mathcal{N}(y_1; x, \sigma^2) \mathcal{N}(y_2; x, \sigma^2) \times \dots \times \mathcal{N}(y_m; x, \sigma^2) \\ &= \frac{1}{\sqrt{(2\pi)^m \sigma^{2m}}} \exp\left(-\frac{\sum_{i=1}^m (y_i - x)^2}{2\sigma^2}\right) \end{aligned}$$

# Оценка максимизации правдоподобия

- ✓ Оценка максимального правдоподобия

$$\hat{x}_{\text{MLE}} = \operatorname{argmax}_x p(\mathbf{y} | x)$$

- ✓ Вместо оптимизации правдоподобия можно взять его логарифм (это не влияет на результат)


$$\begin{aligned}\hat{x}_{\text{MLE}} &= \operatorname{argmax}_x p(\mathbf{y} | x) \\ &= \operatorname{argmax}_x \log p(\mathbf{y} | x)\end{aligned}$$

- ✓ Результат:

$$\log p(\mathbf{y} | x) = -\frac{1}{2\sigma^2} ((y_1 - x)^2 + \dots + (y_m - x)^2) + C$$

- ✓ Также можно применить небольшую хитрость:  
максимизация функции = минимизация обратной функции

$$\operatorname{argmin}_z f(z) = \operatorname{argmin}_z (-f(z))$$



- ✓ Максимизация правдоподобия = минимизация средней квадратичной ошибки

$$\begin{aligned}\hat{x}_{\text{MLE}} &= \operatorname{argmin}_x -(\log p(\mathbf{y} | x)) \\ &= \operatorname{argmin}_x \frac{1}{2\sigma^2} ((y_1 - x)^2 + \dots + (y_m - x)^2)\end{aligned}$$

- ✓ Если измерения имеют различную дисперсию, то это эквивалентно МВНК

$$\hat{x}_{\text{MLE}} = \operatorname{argmin}_x \frac{1}{2} \left( \frac{(y_1 - x)^2}{\sigma_1^2} + \dots + \frac{(y_m - x)^2}{\sigma_m^2} \right)$$



# Важно!

- ✓ **Центральная предельная теорема** говорит нам, что при объединении случайных независимых ошибок их нормализованная сумма стремиться к **нормальному распределению**.

Т.е. они могут быть разумно смоделированы одним нормальным распределением ошибок.

# Важно!

- ✓ Когда мы используем МНК, выбросы измерений могут оказать существенное влияние на нашу окончательную оценку. При 2 ст. откл. (сигма), имеет вероятность возникновения  $<5\%$ .
- ✓ В результате, если в данных измерений есть выбросы, МНК придаст большое значение этим измерениям.
- ✓ Таким образом, оценочные значения нашего параметра будут сильно зависеть от этих выбросов. Наш оптимальный метод будет искажен таким образом, что неточные измерения будут более вероятны.

# Внимание! Выбросы!

- ✓ Мы всегда должны стараться количественно определять распределение ошибок, когда это возможно, до слепого применения максимизации правдоподобия или МНК.
- ✓ Всегда важно с осторожностью относиться к выбросам, которые могут существенно повлиять на наши окончательные оценочные значения.

# Дополнительные материалы

- ✓ <https://likerobotics.ru/teach/courses/sistemyi-ochuvstvleniya-robotov.html>

P.S. Перечень дополнительных материалов на сайте постоянно обновляется...

# Спасибо за внимание!

[www.ifmo.ru](http://www.ifmo.ru)

IT'sMO<sup>re</sup> than a  
UNIVERSITY